

碩士學位 請求論文  
指導教授 申 東 烈

(표지)

# CNN을 이용한 작은 힘의 차이를 가지는 근전도 신호 분류에 관한 연구

成均館大學校 一般大學院

電子電氣컴퓨터工學科

朴 辰 赫

碩士學位 請求論文  
指導教授 申 東 烈

(내표지)

# CNN을 이용한 작은 힘의 차이를 가지는 근전도 신호 분류에 관한 연구

A Study on EMG Signal Classification with Small Force  
Difference Using CNN

成均館大學校 一般大學院

電子電氣컴퓨터工學科

朴 辰 赫

碩士學位 請求論文  
指導教授 申 東 烈

(심사청구서)

# CNN을 이용한 작은 힘의 차이를 가지는 근전도 신호 분류에 관한 연구

A Study on EMG Signal Classification with Small Force  
Difference Using CNN

이 論文을 工學 碩士學位請求論文으로 提出합니다.

2019 年 10 月 日

成均館大學校 一般大學院

電子電氣컴퓨터工學科

朴 辰 赫

(인정서)

이 論文을 朴辰赫의 工學  
碩士學位 論文으로 認定함.

2019 年 12 月 日

審査委員長

---

審査委員

---

審査委員

---

## 목차

|   |    |
|---|----|
| 목차 .....  | i  |
| 그림 목차 .....                                     | ii |
| <br>  |    |
| 제1장 서론 .....                                    | 1  |
| <br>  |    |
| 제2장 관련연구 .....                                  | 4  |
| 2.1 근전도 검사 .....                                | 4  |
| 2.2 근전도 신호를 이용한 연구 .....                        | 5  |
| 2.3 2D-Touch와 3D-Touch .....                    | 6  |
| 2.4 CNN을 이용한 EMG 신호 데이터 분류 .....                | 8  |
| <br>  |    |
| 제3장 2D · 3D-Touch EMG 신호 데이터 수집을 위한 실험 설계 ..... | 9  |
| 3.1 2D · 3D-Touch 입력을 위한 어플리케이션 .....           | 10 |
| 3.2 EMG 신호 데이터 측정기기 Myo .....                   | 11 |
| 3.3 EMG 신호 데이터 수신 및 수집을 위한 어플리케이션 .....         | 12 |
| 3.4 실험 방법 .....                                 | 16 |
| <br>  |    |
| 제4장 CNN 모델의 입력으로 사용하기 위한 EMG 신호 데이터 변환 .....    | 18 |
| 4.1 Raw EMG data .....                          | 19 |
| 4.2 Normalization EMG data .....                | 21 |
| 4.3 Spectrogram EMG data .....                  | 22 |

|  |    |
|--|----|
| 제5장 VGGNet을 이용한 EMG 신호 데이터 분류 .....                        | 24 |
| 5.1 EMG 신호 데이터 분류를 위한 VGGNet 설정 .....                      | 24 |
| 5.2 VGGNet을 통한 EMG 신호 데이터 분류 결과 .....                      | 25 |
| 제6장 VGGNet을 이용한 EMG 신호 데이터 분류 .....                        | 26 |
| 6.1 EMG 신호 데이터 분류를 위한 Basic 모델 설정 .....                    | 26 |
| 6.2 Basic 모델을 통한 EMG 신호 데이터 분류 결과 .....                    | 27 |
| 6.2.1 Raw EMG data를 통한 VGGNet과 Basic 모델 비교 .....           | 27 |
| 6.2.2 Normalization EMG data를 통한 VGGNet과 Basic 모델 비교 ..... | 28 |
| 6.2.3 Spectrogram EMG data를 통한 VGGNet과 Basic 모델 비교 .....   | 29 |
| 6.3 데이터 특성을 파악한 새로운 이미지화 방안 .....                          | 30 |
| 6.3.1 Stack을 이용한 센서별 가중치 설정에 따른 이미지화 .....                 | 30 |
| 제7장 결론 .....   | 33 |
| 참고문헌 .....   | 26 |
| Abstract .....   | 26 |

## 그림목차

|  |    |
|--|----|
| 그림 1. (a) 표면 근전도 검사, (b) 침 근전도 검사 .....      | 4  |
| 그림 2. 임계값에 따른 터치 영역 구분 .....                 | 6  |
| 그림 3. EMG 신호 데이터 수집 구조 .....                 | 9  |
| 그림 4. 2D-Touch와 3D-Touch 입력을 위한 어플리케이션 ..... | 10 |
| 그림 5. EMG 신호 데이터 수집기기 Myo .....              | 11 |
| 그림 6. Myo 센서 번호 .....                        | 11 |

|  |    |
|--|----|
| 그림 7. EMG 신호 데이터 수신 및 수집 어플리케이션 .....                          | 12 |
| 그림 8. 컴퓨터와 Myo 블루투스 연결 .....                                   | 13 |
| 그림 9. 어플리케이션 실행 후 첫 화면 .....                                   | 13 |
| 그림 10. 데이터 수신 및 수집을 마치고 종료하는 화면 .....                          | 14 |
| 그림 11. 수집된 데이터 정보 .....  | 14 |
| 그림 12. 저장된 EMG 신호 데이터의 구조 .....                                | 15 |
| 그림 13. Myo 착용 방법 .....   | 16 |
| 그림 14. 실험 자세 .....   | 17 |
| 그림 15. (a) Raw_EMG_each 데이터, (b) Raw_EMG_all 데이터 .....         | 19 |
| 그림 16. EMG 신호 데이터 Normalization 과정 .....                       | 21 |
| 그림 17. Spec_EMG 데이터 .....                                      | 23 |
| 그림 18. VGG Net을 이용한 EMG 신호 데이터 분류 결과 .....                     | 25 |
| 그림 19. Basic 모델의 구성 .....                                      | 27 |
| 그림 20. Raw EMG data를 통한 각 모델 간 정확도 비교 .....                    | 28 |
| 그림 21. Normalization EMG data를 통한 각 모델 간 정확도 비교 .....          | 30 |
| 그림 22. Spectrogram EMG data를 통한 각 모델 간 정확도 비교 .....            | 31 |
| 그림 23 (a) Stack을 통한 3D-Touch 데이터 변환, (b) 2D-Touch 데이터 변환 ..... | 33 |
| 그림 24 Basic 모델을 통한 제안한 Stack EMG data 분류 정확도 비교 .....          | 34 |

## 논문요약

# CNN을 이용한 작은 힘의 차이를 가지는 근전도 신호 분류에 관한 연구

근전도 신호란 사람이 특정한 동작을 취하였을 경우, 활성화되는 근육세포에서 발생하는 전기적인 신호이다. 이를 이용하여 다양한 분야에 활용하려고 하는 연구가 진행되었다. 일반적인 근전도 신호의 활용 분야는 의료분야에서 사람의 신체검사 또는 재활용으로 사용되고 있으며, 산업 분야에서는 작업자의 근전도 신호를 이용하여 로봇 팔 또는 로봇 다리 등을 제어하는 용도로 사용된다. 하지만 현재까지의 연구는 힘의 차이가 큰 행동들을 분류하고 이를 통해 로봇 팔이나 로봇 다리 등과 같은 디바이스를 제어하는 연구에 치중되어 있다. 미세한 힘의 차이를 가지는 행동들은 분류할 수 있는 방안이 적다. 이에 따라 본 논문에서는 미세한 힘의 차이를 가지는 근전도 신호를 분류하는 방안을 제시한다. 미세한 힘의 차이를 가지는 근전도 신호 측정을 위해 2D-Touch와 3D-Touch 입력 방식을 통해 데이터를 수집한다. 수집한 데이터를 CNN(Convolutional Neural Network)를 통해 분류하는 작업을 진행한다.

2D-Touch와 3D-Touch 두 터치 입력 방식을 통해 수집한 데이터를 CNN 모델의 입력 데이터로 사용하기 위해 이미지화하는 과정을 진행하였다. Raw, Normalization, Spectrogram으로 3가지의 이미지로 변환한 후, CNN의 대표적인 모델 중 하나인 VGG Net을 이용하여 분류한 결과 90% 이상의 성공률을 보였지만, 특정



피험자 또는 특정 데이터들이 잘 분류되지 않는 결과를 보였다. 따라서 VGG Net을 대체하기 위한 모델인 Basic 모델을 제작하였고, 앞서 사용한 3가지의 이미지화 방법 이외에 Stack이라는 이미지화 방법을 이용하여 추가적으로 데이터를 제작하였다. 이를 이용하여 분류한 결과 특정... 피험자, 데이터를 잘 분류하지 못하는 기존의 VGG Net에 비해 잘 분류하는 결과를 보였다. 본 논문의 연구 결과를 기반으로 미세한 힘의 차이를 가지는 근전도 신호를 분류하여 기존보다 넓은 분야로 사용할 수 있고, 3D-Touch를 지원하지 않는 기기에서 근전도 신호를 이용하여 3D-Touch 인터페이스를 지원할 수 있을 것으로 기대된다.

주제어 : 2D-Touch, 3D-Touch, EMG, VGG Net

## 제1장 서론

근전도(EMG, Electromyogram) 검사란 사람이 특정한 동작을 취하였을 경우, 활성화되는 근육세포에서 발생하는 전기적인 신호를 측정하고 기록하는 검사다 [1]. 근전도 신호는 근육세포에서 발생하는 전기적인 신호를 탐지하는 근전도 센서를 통해 수집한다. 근전도 신호를 수집하는 방법에는 표면 근전도 검사와 침 근전도 검사가 있다 [2]. 표면 근전도 검사란 피부에 근전도 센서를 부착하여 수집하는 방법이고, 침 근전도 검사란 바늘을 피부 내 근육에 삽입하여 수집하는 방법이다. 이렇게 수집된 근전도 신호를 이용, 신호들의 특징을 통하여 각 동작을 분류한다.

이전의 연구에서는 근전도 신호를 이용하여 로봇 팔을 제어하는 연구가 진행되었다 [3]. 이 연구에서 피험자는 근전도 센서를 팔에 부착한 후, 측정 동작을 취하면 해당 동작에 맞는 근전도 신호를 분석하여 로봇 팔을 움직이게 하였다. 피험자가 취한 동작은 팔을 굽히는 동작, 팔을 펴는 동작 등 각 동작을 취할 때 사용하는 근육과 힘이 명확하게 구분된다. 또한, 로봇 팔 뿐만 아니라 로봇 손을 제어하는 연구도 진행되었다 [4]. 손가락을 제어하는 동작에는 피험자가 손가락을 모두 펴는 동작, 손가락을 모두 굽혀 주먹을 쥐는 동작 등을 취하여 로봇 손가락이 이를 따라 동작하는 연구였다. 이러한 연구에서도 손을 이용한 각 동작의 특징이 명확하게 구분된다. 팔을 펴는 동작과 팔을 굽히는 동작 등 각 동작이 사용하는 근육과 각 근육을 사용하는 힘에 따라 근전도 신호가 명확하게 다르다. 따라서 동작마다 측정되는 근전도 신호의 값이 확연하게 다르게 발생한다. 이는 근전도 신호의 값의 차이가 큰 동작들은 분류가 더 쉽게 되는 것을 뜻한다. 반면에 동작의 특징이 명확하게 구분되지 못하면 그에 따라 각 동작에 해당하는 근전도 신호의 값의 차이가 크지

못하므로 각 동작을 분류하는데 어려움을 갖는다.

근전도 신호의 차이가 작은 대표적인 동작으로는 사용자가 스크린을 터치하는 행동이 있다. iPhone에서 사용되는 터치 동작은 스크린을 터치하는 동작으로는 2D-Touch의 ‘Touch’와 3D-Touch의 ‘Touch’, ‘Peek’, ‘Pop’이 있다. 3D-Touch에서 ‘Touch’는 사용자가 스크린을 200g 이하의 힘으로 터치하는 행동이다 [5]. ‘Peek’이란 사용자가 스크린을 200g 이상, 400g 이하의 힘으로 터치하는 행동이고, ‘Pop’은 400g 이상의 힘으로 스크린을 터치하는 행동이다. 즉, 3가지 행동 모두 동일한 행동을 취하지만 힘의 세기에 따라 구분되는 동작이다. 즉, 근전도 신호에서 매우 작은 신호의 변화를 발생할 수 있는 동작이다

이전의 연구에서는 근전도 신호를 이용하여 ‘Touch’, ‘Peek’, ‘Pop’를 구분하는 연구가 진행되었다. CNN의 모델 중 하나인 VGG Net을 이용하여 각 터치 입력 방식을 분류하였는데 ‘Touch’와 ‘Pop’은 잘 분류하였으나 ‘Touch’와 ‘Peek’, ‘Peek’과 ‘Pop’은 잘 분류하지 못하였다. 즉, 200g이상 힘의 차이가 발생하지 않은 근전도 신호는 잘 분류하지 못한다.

본 논문에서는 데이터 간 값의 차이가 작은 근전도 신호를 분류하기 위해 3D-Touch의 ‘Touch’, ‘Pop’을 통해 발생하는 근전도 신호를 통해 이와 같은 동작을 구분하는 방안을 제안한다. 이를 위해 본 논문에서는 데이터 간 값의 차이가 작은 근전도 신호를 분류하는 방안으로 딥러닝 모델 중 하나인 CNN을 이용하여 제시하고자 한다. 데이터 간 값의 차이가 작은 근전도 신호 수집을 위해 3D-Touch의 ‘Touch’, ‘Pop’ 두 가지 동작을 수행한다. 수집한 근전도 신호를 CNN 모델에 이용하기 위해서는 이미지 데이터로 변환하는 데이터 전처리 과정을 수행해야 한다 [6]. 변환된 이미지 데이터를 분류에 사용되는 가장 대표적인 CNN 네트워크

중 하나인 VGG Net을 이용하여 분류한다 [7]. 또한, VGG Net 이외에 근전도 신호를 잘 분류하는 모델을 제안한다.

## 제2장 관련 연구

### 2.1 근전도 검사

근전도 검사란 특정한 동작을 취하였을 경우, 근육세포의 미세한 움직임으로 인해 발생하는 전기적인 신호를 측정하고 기록하는 검사이다. 근전도 신호를 측정하는 방법으로는 표면 근전도 검사와 침 근전도 검사가 있다. 표면 근전도 검사는 그림 1-(a)와 같이 피부 표면에 근전도 수집 센서를 부착하여 근전도 신호를 측정하는 방식이고, 침 근전도 검사는 그림 1-(b)와 같이 가는 침을 근육에 삽입하여 근전도 신호를 측정하는 방식이다.

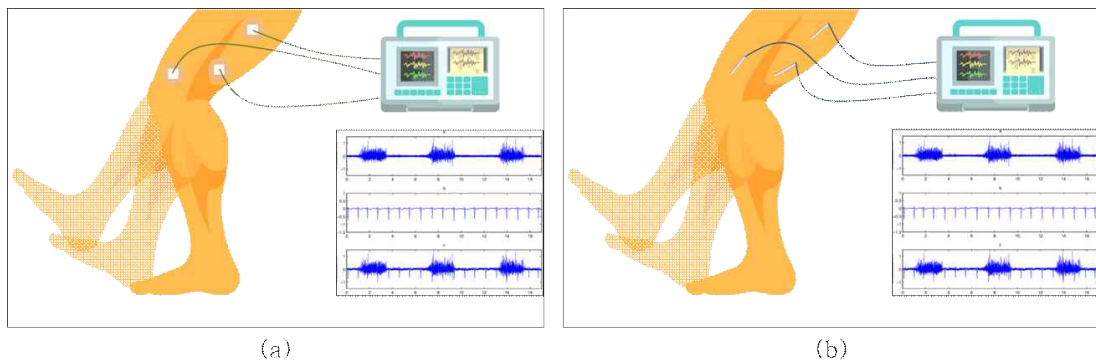


그림 1. (a) 표면 근전도 검사, (b) 침 근전도 검사

## 2.2 근전도 신호를 이용한 연구

근전도 신호를 이용한 다양한 연구가 진행되었다. P. K. Artemiadis의 “EMG-Based Control of a Robot Arm Using Low-Dimensional Embeddings” 논문은 근전도 신호를 이용하여 로봇 팔의 제어 인터페이스를 연구하였다. 수집한 근전도 신호를 기반으로 해당 신호가 어떤 행동에 관한 건지에 대해 3D로 모델링 하였다. 실험결과 이전의 연구와는 다르게 로봇 팔 제어를 위한 인터페이스를 사용자에게 쉽게 교육할 수 있고 디코딩 모델을 쉽게 구축할 수 있어 소요되는 시간을 단축 시킬 수 있었다.

D. Leonardis의 “An EMG-Controlled Robotic Hand Exoskeleton for Bilateral Rehabilitation” 논문은 근전도 신호를 이용하여 뇌졸중 환자들의 재활을 돕는 로봇 손을 개발한다. 개발된 손은 환자들의 실제 손 크기와 적응할 수 있고 또한, 실제 로봇 손을 이용하여 물체를 잡을 때 느껴지는 촉감의 잔류 감각 지각 능력, 두 가지의 뚜렷한 특징을 가지고 설계되었다. 착용하고 있지 않은 로봇 손의 움직임은 실시간으로 반대편 손의 근전도 신호를 받아 복제를 진행한다. 개발한 로봇 손을 이용하여 뇌졸중 환자를 대상으로 파일럿 실험을 한 결과 실제 손에서 가하는 힘과 로봇 손에서 가하는 힘의 오차 범위가 13 ~ 27%로 비교적 낮은 오차율을 가졌다.

## 2.3 2D-Touch와 3D-Touch

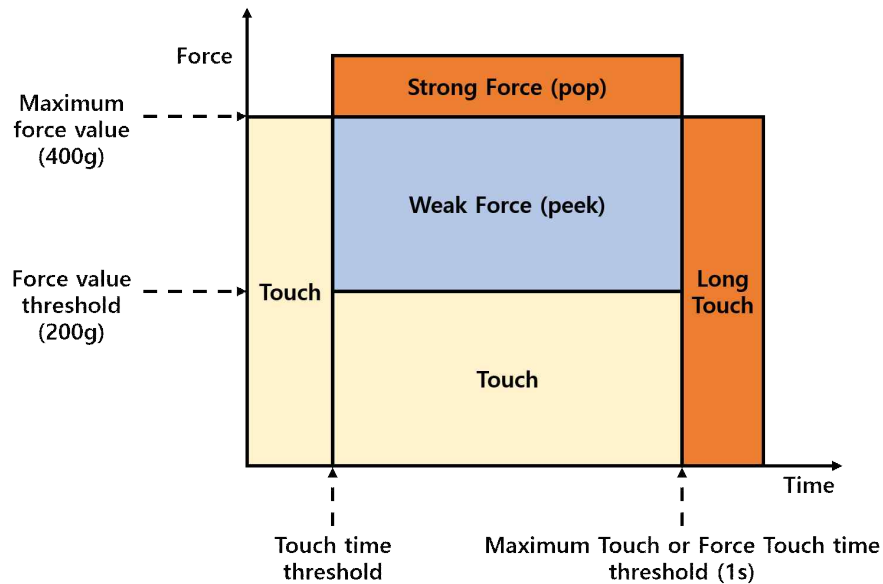


그림 2. 임계값에 따른 터치 영역 구분

일반적인 2D-Touch는 사용자가 디스플레이를 터치할 시, 터치되는 위치에 해당하는 값인 x축과 y축에 따라 터치 인터랙션이 동작하는 터치 방식이다. 이와 다르게 3D-Touch는 기존의 2D-Touch에서 사용자가 디스플레이를 터치하는 강도에 해당하는 값인 z축을 추가하여 입력으로 받아 터치 인터랙션이 동작하는 터치 방식이다. Apple사의 iPhone에서는 3D-Touch의 영역을 크게 2가지로 나누었다. 약한 힘으로 터치하였을 때의 터치 인터랙션을 ‘Peek’, 강한 힘으로 터치하였을 때의 터치 인터랙션을 ‘Pop’ 으로 구분하였다. 그림 2는 2D-Touch와 3D-Touch를 시간과 포스값, 두 임계값으로 나눈 영역이다. 기본적으로 사용자가 디스플레이를 터치할 시 발생하는 힘은 Touch 영역 안이라고 구분하고, 터치함과 동시에 포스값이 증가하게

되며 발생하는 힘은 포스영역 안이라고 구분한다. 또한 디스플레이를 터치하는 힘에 대한 터치 입력 방식에 상관없이 1초가 지나게 되면 ‘Long Touch’ 영역으로 구분한다. iPhone에서는 포스값이 200g이상 400g미만의 약한 힘으로 디스플레이를 터치하게 되면 ‘Peek’ 으로, 디스플레이가 입력받을 수 있는 최댓값인 400g이상의 강한 힘으로 디스플레이를 터치하게 되면 ‘Pop’ 으로 구분한다.

3D-Touch 인터페이스를 사용하는 대표적인 예로 아이폰에서는 사용자가 갤러리에서 특정 사진에 ‘Peek’ 을 입력하게 되면 팝업형식으로 해당 사진을 미리 보는 기능을 제공한다. 또한 ‘Pop’ 을 입력하게 되면 해당 사진을 전체화면을 보여주게끔 화면을 전환하는 기능을 제공한다.



## 2.4 CNN 모델을 이용한 EMG 신호 데이터 분류

EMG 신호를 사용할 때 CNN(Convolutional Neural Network)를 이용하는 이유는 레이블되지 않은 데이터 이용이 가능하다. hand-crafted 특징보다 잠재적으로 더 나은 특징을 배울 수 있다. 이 방법 자체가 사용자가 다른 EMG 패턴을 알기에 적합하다 [8].

CNN(convolutional neural network)의 아키텍처는 기존의 ANN(artificial neural network)와는 다르다. CNN은 3가지의 메인 타입의 레이어를 포함하고 있다. 3가지 레이어는 convolutional layer, pooling layer and fully connected layer이다. 각 레이어는 레이어의 수를 포함하는 블록을 표현한다. Convolution과 pooling의 동작은 최적화된 feature map을 제공하기 위해 필터를 사용하여 input data에 적용한다. 이러한 feature map은 convolution layer의 마지막 output으로 활용된다. classification은 마지막 fully connected layer에서 작동한다 [9]. 이미지의 특징을 추출하는 부분과 이미지를 분류하는 부분 사이에 이미지 형태의 데이터를 배열 형태로 만드는 flatten 레이어가 위치한다. 이러한 특징은 fully connected 레이어와 비교하여 다음과 같은 차별성을 갖는다. 첫째, 각 레이어의 입출력 데이터의 형상을 유지한다. 둘째, 이미지 공간 정보를 유지하면서 인접 이미지와의 특징을 효과적으로 인식한다. 셋째, 복수의 필터로 이미지의 특징 추출 및 학습한다. 넷째, 추출한 이미지의 특징을 강화하는 pooling 레이어를 갖는다. 다섯째, 필터를 공유 파라미터로 사용하기 때문에, 일반적인 ANN과 비교하여 학습 파라미터가 매우 적다.

### 제3장 2D · 3D-Touch EMG 신호 데이터 수집을 위한 실험 설계

본 논문의 목표인 EMG 신호 데이터 간의 차이가 아주 작을 경우, 각 데이터를 구분할 수 있는지에 대한 실험을 진행한다. 첫 번째 단계로 데이터 간의 차이가 아주 작은 EMG 데이터를 2D-Touch와 3D-Touch 입력을 통해 수집한다. 데이터 수집을 위해서는 모바일 어플리케이션을 개발하고, 개발된 모바일 어플리케이션을 통해 2D-Touch와 3D-Touch를 구분하여 입력한다. 각 터치 방식을 입력할 때, 착용하고 있는 Myo와 연동된 데스크톱 어플리케이션에서 데이터를 수집한다. 그림 3은 개발한 어플리케이션과 Myo를 통해 EMG 신호 데이터를 수집하는 구조를 보여준다.



그림 3. EMG 신호 데이터 수집 구조

### 3.1 2D · 3D-Touch 입력을 위한 어플리케이션

2D-Touch 및 3D-Touch EMG 신호 데이터 수집을 위하여 피험자가 2D-Touch 및 3D-Touch를 구분하여 입력할 수 있는 어플리케이션을 개발한다. 해당 어플리케이션을 사용하기 위해서는 3D-Touch를 지원하는 디스플레이가 탑재된 디바이스를 사용해야 한다. 따라서 본 실험에서는 iOS 기반의 Apple사의 iPhone 7 Plus를 사용한다. 개발된 어플리케이션은 그림 4와 같다. 어플리케이션을 실행하면 각 터치 방식을 입력할 수 있는 버튼이 있고 해당 버튼 상단에는 피험자가 버튼을 터치하는 힘의 세기인 포스 값이 표시된다.




그림 4. 2D-Touch와 3D-Touch 입력을 위한 어플리케이션

### 3.2 EMG 신호 데이터 측정 기기 Myo

본 실험에서 EMG 신호 데이터를 측정하기 위한 기기로 Myo를 사용한다. Myo는 그림 5와 같이 EMG 8개의 신호 데이터를 측정할 수 있는 센서가 원형형태로 부착되어 있다. Myo를 통해 EMG 신호 데이터를 측정할 시, 데이터 값은 -127 ~ +128의 범위를 가진다. 그림 6과 같이 Myo는 센서별로 센서 번호가 있다. 따라서 Myo를 이용하여 EMG 신호 데이터를 측정할 시 일관성을 위하여 각 센서 번호에 유의하여 부착해야 한다.



그림 5. EMG 신호 데이터 수집기기 Myo



그림 6. Myo 센서 번호

### 3.3 EMG 신호 데이터 수신 및 수집을 위한 어플리케이션

본 실험에서 Myo로부터 EMG 신호 데이터 수신받아 수집하는 어플리케이션으로 Myo에서 제공하고 있는 SDK를 이용하여 그림 7과 같이 프로그램을 개발하였다. 피험자가 Myo를 착용한 후, 컴퓨터와 블루투스 연동을 하면 그림 8과 같이 연동되었다는 것을 확인할 수 있다 [10].

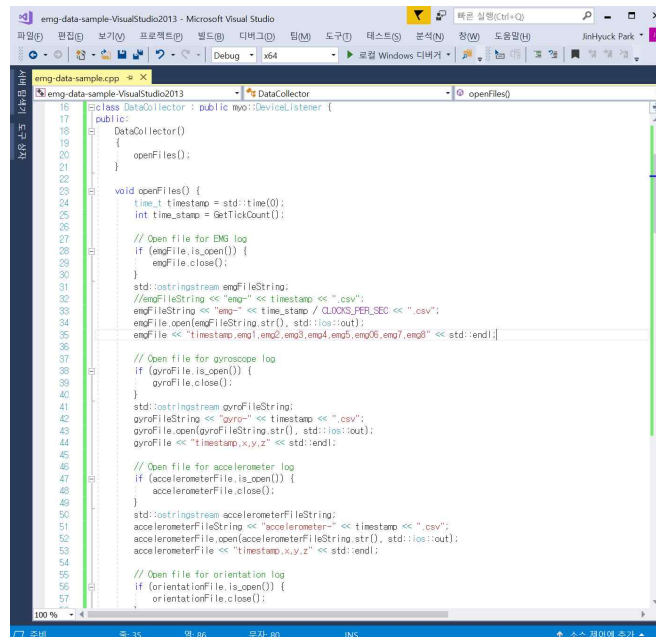


그림 7. EMG 신호 데이터 수신 및 수집 어플리케이션

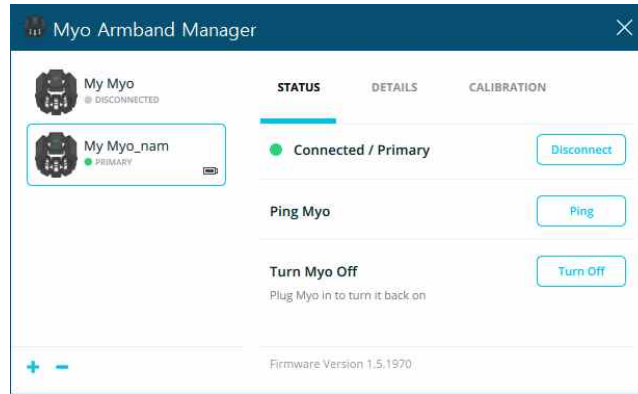


그림 8. 컴퓨터와 Myo 블루투스 연결

컴퓨터와의 연동작업을 마친 후, 어플리케이션을 실행하면 그림 9와 같이 Myo와 연결되었다는 문구와 함께 EMG 신호 데이터를 수신 및 수집한다. 수집되는 EMG 신호 데이터는 200Hz로 1초당 200개의 신호가 수집된다. 수집을 모두 마치게 되면 그림 10과 같이 종료한다.

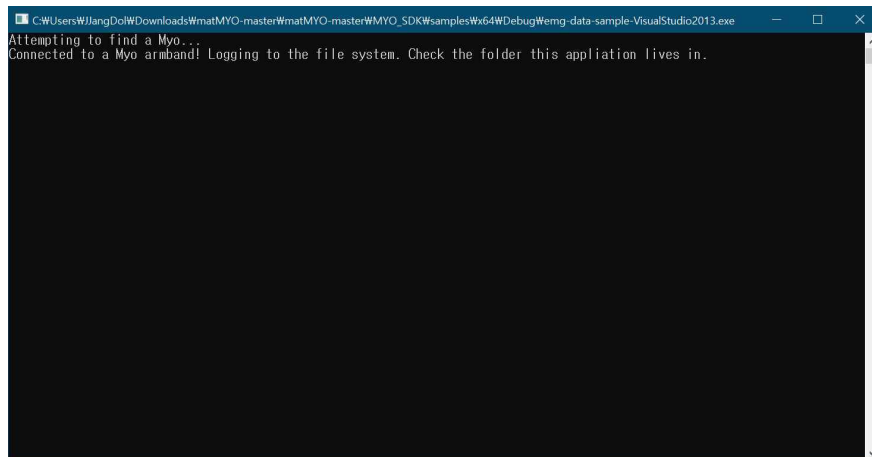


그림 9. 어플리케이션 실행 후 첫 화면




그림 10. 데이터 수신 및 수집을 마치고 종료하는 화면

어플리케이션을 이용하여 EMG 신호 데이터를 수집하게 되면 그림 11과 같이 총 4개의 CSV 파일로 저장된다. 해당 파일은 각각 Myo를 착용한 부위의 근육세포가 발생시키는 EMG 값, Myo의 가속도 값, 자이로 값 그리고 방향 값이 저장되어 있다.

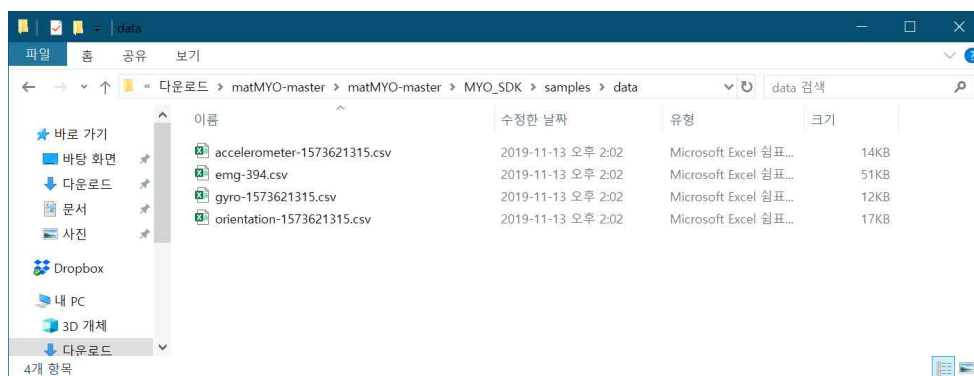
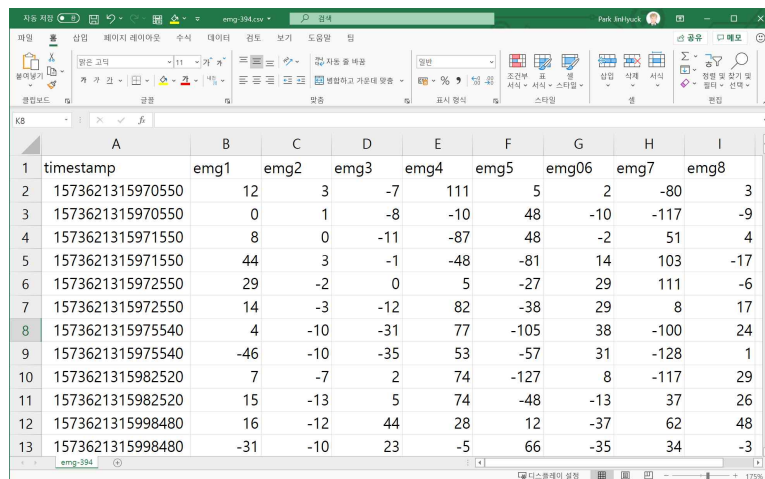


그림 11. 수집된 데이터 정보

본 실험에서는 EMG 신호 데이터만을 필요로 하므로 Myo의 가속도 값, 자이로 값 그리고 방향 값은 사용하지 않는다. EMG 신호 데이터가 저장된 CSV파일을 살펴보면 그림 12와 같은 구조를 가진다. 첫 번째 열은 값들이 수집된 시간이고 다음 열부터 센서 번호를 기준으로 차례대로 센서별로 수집된 값들이 저장된다.



|    | A                | B    | C    | D    | E    | F    | G    | H    | I    |
|----|------------------|------|------|------|------|------|------|------|------|
|    | timestamp        | emg1 | emg2 | emg3 | emg4 | emg5 | emg6 | emg7 | emg8 |
| 2  | 1573621315970550 | 12   | 3    | -7   | 111  | 5    | 2    | -80  | 3    |
| 3  | 1573621315970550 | 0    | 1    | -8   | -10  | 48   | -10  | -117 | -9   |
| 4  | 1573621315971550 | 8    | 0    | -11  | -87  | 48   | -2   | 51   | 4    |
| 5  | 1573621315971550 | 44   | 3    | -1   | -48  | -81  | 14   | 103  | -17  |
| 6  | 1573621315972550 | 29   | -2   | 0    | 5    | -27  | 29   | 111  | -6   |
| 7  | 1573621315972550 | 14   | -3   | -12  | 82   | -38  | 29   | 8    | 17   |
| 8  | 1573621315975540 | 4    | -10  | -31  | 77   | -105 | 38   | -100 | 24   |
| 9  | 1573621315975540 | -46  | -10  | -35  | 53   | -57  | 31   | -128 | 1    |
| 10 | 1573621315982520 | 7    | -7   | 2    | 74   | -127 | 8    | -117 | 29   |
| 11 | 1573621315982520 | 15   | -13  | 5    | 74   | -48  | -13  | 37   | 26   |
| 12 | 1573621315998480 | 16   | -12  | 44   | 28   | 12   | -37  | 62   | 48   |
| 13 | 1573621315998480 | -31  | -10  | 23   | -5   | 66   | -35  | 34   | -3   |

그림 12. 저장된 EMG 신호 데이터의 구조



### 3.4 실험 방법

먼저 피험자는 EMG 신호 데이터 수집기기인 Myo를 그림[8]과 같이 착용한다. 이때 수집되는 EMG 신호 데이터의 일관성을 위하여 피험자들은 팔을 앞으로 뻗은 상태에서 4번 센서가 위로 향하도록 착용한다 [11].



그림 13. Myo 착용 방법

Myo를 착용한 후, 총 4명의 피험자는 그림[10]와 같이 편한 자세로 앉은 후, 양손으로 스마트 폰을 쥐고 개발된 어플리케이션을 통해 2D-Touch와 3D-Touch를 5회씩 입력한다. 피험자는 다음과 같은 어플리케이션의 변화를 보고 각 터치 입력방식을 입력한다.



그림 14. 실험 자세

2D-Touch의 ‘Touch’와 3D-Touch의 ‘Pop’을 각각 5번씩 입력하여 EMG 신호 데이터를 수집한다. 총 5번의 입력 중에서 3회분은 train data로 나머지 2회분 중 각각 1회분씩 validation data와 test data로 사용한다.

## 제4장 CNN 모델의 입력으로 사용하기 위한 EMG 신호 데이터 변환

Myo는 200Hz로 데이터를 측정하기 때문에 1초에 약 200개의 EMG 신호를 발생한다. 이는 8개의 채널에서 각각 수집된 데이터를 포함한다. 따라서 Raw data를 CNN 모델의 입력 데이터로 사용하기 위해서는 8개의 채널에서 수집된 EMG 신호 데이터를 모두 이미지화해야 한다. Myo를 통해 수집한 2D-Touch와 3D-Touch의 EMG 신호 데이터는 이미지로 변환하여 CNN 모델로 분류할 수 있다. 따라서 EMG 신호 데이터를 이미지로 변환할 때에는 데이터를 다음과 같은 방법으로 변경하여 CNN 모델에 입력 데이터로 사용할 수 있다. 첫째, 수집한 EMG 신호 데이터의 수치를 그대로 이미지화하여 사용하는 방법, 둘째는 frequency의 특징을 추출하여 이를 이미지화하여 사용하는 방법, 셋째는 EMG 신호 데이터를 정규화 작업을 통해 일정한 신호 데이터 값을 추출하여 이미지화하여 사용하는 방법이다.

## 4.1 Raw EMG data

수집된 EMG 신호 데이터를 특정한 변환 방법을 거치지 않고 그대로 이미지로 사용하는 방법으로는 2가지가 있다. 센서별로 수집할 수 있는 범위인  $-127 \sim +128$ 에 맞게 설정하여 센서별로 수집한 데이터를 센서의 순서에 맞게 그림 15-(a)와 같이 이미지화하는 방법이다. 이때, 각각의 센서마다 다른 색상으로 나타낸다. 또 다른 방법은 각각의 센서별로 수집한 EMG 신호 데이터를 그림 15-(b)와 같이 표현하는 방식이다. 이는 센서들을 직접 비교할 수 있어 특정한 EMG 신호를 송신하는 센서들을 구분할 수 있다. 본 논문에서는 Raw EMG 데이터로 그림 15-(b)와 같은 이미지 변환 방법을 이용하여 이미지 데이터로 변환한 후, 입력 데이터로 사용하여 CNN 모델을 통하여 입력 데이터를 분류하였다.




그림 15. (a) Raw\_EMG\_Each 데이터, (b) Raw\_EMG\_all 데이터

이는 그림 15-(a)와 같은 이미지 변환 방식을 사용할 경우 EMG 신호 데이터의 값을 표현하는 데 있어서 CNN 모델이 해당 이미지의 특징을 추출할 만큼의 차이를 표현하지 못하기 때문이다. 즉, 본 논문이 구분하려는 작은 변화의 EMG 신호 데이터를 표현하는 데 한계를 가진다. 따라서 그림 15-(b)와 같이 각 센서에서 수집된 EMG 데이터를 직접적으로 비교하여 이를 표현하였을 경우에 그 특징을 더 잘 추출할 수 있다.

## 4.2 Normalization EMG data

time-domain을 통한 특징 추출을 위한 이전의 연구들 [12, 13]에서 EMG 신호 데이터를 분류하기 위해서 Normalization과정을 통해 특정한 EMG 신호를 파악하였다. 이를 위해 그림 16과 같은 과정을 통해 processed signal을 만든다. 먼저 수집된 Raw EMG signal은 signal의 평균값으로 제거한다. Raw surface EMG는 20 ~ 150Hz 사이의 spectral power dominant를 포함하는 6 ~ 500Hz의 frequency content를 가진다. 따라서 우리는 high pass filter를 이용해서 20Hz이하의 frequency value를 filter out 하고 450Hz이상의 frequency value를 제거한다. 이는 4th order Butterworth digital filter를 이용하는 방법이다. 다음으로는 Rectification을 통해 절대값으로 값을 변경하고 이동평균을 통해 값을 smoothing한다. 이를 통해 processed signal을 구할 수 있다 [14].

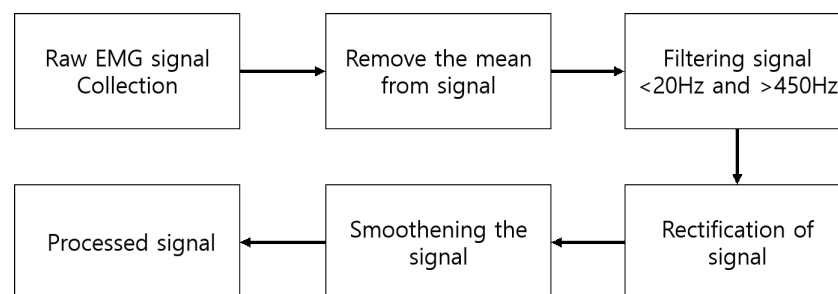


그림 16. EMG 신호 데이터 Normalization 과정

### 4.3 Spectrogram EMG data

EMG 신호 데이터를 이미지화하는 또 다른 위한 방법은 frequency를 통한 특징을 찾아낼 수 있게 spectrogram으로 변경하는 것이다. temporal features들이 구현하기에 빠르고 쉽게 알기 위해서는 frequency-domain으로부터 추출된 특징과 비교하여야 한다. time-frequency domain의 특징은 spectrogram, wavelet transform, wavelet packet transform보다 pattern 정보를 추출하는데 좋은 방법이 될 수 있다 [15]. 따라서 이러한 방법은 linear, non-linear, supervised or unsupervised와 같은 방법에서 특징의 set으로부터 알려지지 않은 pattern들을 추출하는데 도움이 된다 [16, 17]. 따라서 Short-Time Fourier Transform(STFT)는 surface EMG data의 분류에 사용되어져 왔다 [18]. 특히 Convolutional Neural Networks로 surface EMG data를 분류하기 위해 spectrogram의 형태로 만들어진 STFT 특징은 입력 방법으로서 사용되어져 왔다 [19, 20]. STFT는 전체 신호를 processing하는 것 대신에 windows라고 하는 raw signal보다 더 작은 segments로 분리한다. 그리고 나서 Fourier Transform을 통해 각 segment를 변경한다. spectrogram은 주어진 time interval에 나타나는 frequency에 대한 정보를 제공한다. window size가 크면 더 많은 frequency resolution이 좋고, time resolution이 낮다. 반면에 window size가 낮으면 time resolution은 좋고 frequency resolution은 낮다. optimal한 window size를 찾기 위해서는 분석을 통해 이루어진다.

본 논문에서는 사용자의 입력을 반응할 수 있는 시간 300ms안에 이를 처리해야 하므로 200ms으로 window size를 설정하였다 [21]. 이를 통해 그림 17과 같이 EMG signal 신호를 spectrogram으로 이미지화 하였다.




그림 17. Spec\_EMG 데이터



## 제5장 VGGNet을 이용한 EMG 신호 데이터 분류

### 5.1 EMG 신호 데이터 분류를 위한 VGGNet 설정

실험에 사용된 VGGNet은 Convolutional layer가 16개가 쌓여서 구성된 VGG16모델이다. 이를 이용하여 모델을 학습하는 과정에서 최대 epoch는 300으로 설정하였다. overfitting을 방지하기 위해 callback 함수를 통해 val\_loss 값이 낮아지지 않을 경우, 15번의 patience를 기다리고 난 후에 최적의 모델을 저장하여 이를 검증하였다. 또한, 10번의 평가를 통해 평균적으로 나오는 accuracy를 계산하였다. 3가지 형태의 EMG 신호 데이터를 비교하기 위해서 CNN 모델 중 이미지를 분류하는 대표적인 네트워크인 VGGNet을 이용하여 비교하였다. batch size는 16으로 설정하고, target 이미지의 크기는 100x100으로 변경하였다. steps for epoch는 100으로 설정하고 최대 epoch는 300으로 설정하였다. overfitting을 방지하기 위해 callback 함수를 통해 val\_loss 값이 낮아지지 않을 경우, 15번의 patience를 기다리고 난 후에 최적의 모델을 저장하여 이를 검증하였다. 또한, 10번의 평가를 통해 평균적으로 나오는 accuracy를 계산하였다.

## 5.2 VGGNet을 통한 EMG 신호 데이터 분류 결과

각 피험자별로 EMG의 신호를 구분할 결과는 그림 18과 같다. 피실험자 1과 같은 경우, Raw EMG 데이터를 사용하더라도 100% 구분이 가능하다. 반면에 D3 피실험자의 Raw EMG 데이터로는 약 50%의 정확도를 가짐을 알 수 있다. 또한, Normalization 및 spectrogram으로 변경된 이미지를 사용하여 분류했을 경우에도 비슷한 결과를 나타낸다. 즉, VGGNet이 사람마다의 입력에 대한 EMG 신호 데이터를 구분하는데 차이를 많이 보임을 알 수 있다. Raw EMG 데이터와 Normalization 그리고 Spectrogram을 비교하면, 전체적으로 Raw EMG 데이터를 분류하는 것이 더 좋은 결과를 나타낸다. 그리고 Spectrogram의 경우 D2를 제외한 경우 가장 낮은 결과를 나타낸다. 따라서 본 논문에서는 VGGNet을 대체하기 위한 방안을 제시한다.

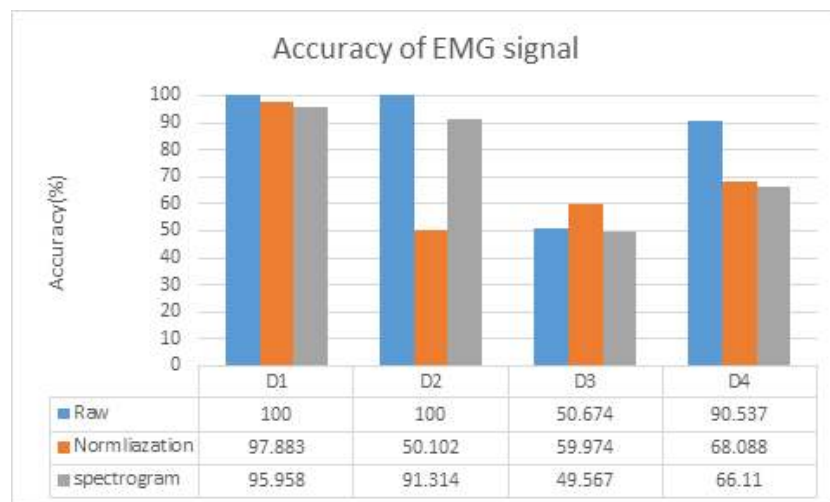


그림 18. VGGNet을 이용한 EMG 신호 데이터 분류 결과

## 제6장 Basic 모델을 이용한 EMG 신호 데이터 분류

### 6.1 EMG 신호 데이터 분류를 위한 Basic 모델 설정

앞서 사용한 CNN모델 중 하나인 VGG Net을 이용하여 EMG 신호 데이터를 분류한 결과 특정 피험자와 특정 데이터에서 분류를 잘하지 못하는 결과를 보였다. 이는 VGG Net이 EMG 신호 데이터와 같은 특징이 적은 그래프 이미지를 분류하는 목적보다 일반적으로 개, 고양이와 같은 특징이 많은 이미지를 분류하는데 특화되어 있기 때문이다. 특징이 적은 데이터를 특징을 많이 추출하는 모델에 학습을 하게 되면 학습에 필요한 특징 이외에 불필요한 특징이 학습되기 때문에 분류하는 정확도가 현저히 줄어든다. 따라서 Convolution layer층을 적게 쌓아 특징을 기존의 VGG Net보다 적게 추출하는 모델을 만들어 실험을 진행한다. Basic모델의 구성은 그림 19와 같다. Convolutional layer를 3개로 모델을 만들었다.

3가지 형태의 EMG 신호 데이터를 비교하기 위해서 CNN 모델 중 이미지를 분류하는 대표적인 네트워크인 VGGNet을 이용하여 비교하였다. batch size는 16으로 설정하고, target 이미지의 크기는 100x100으로 변경하였다. steps for epoch는 100으로 설정하고 최대 epoch는 300으로 설정하였다. overfitting을 방지하기 위해 callback 함수를 통해 val\_loss 값이 낮아지지 않을 경우, 15번의 patience를 통해 학습을 종료하도록 설정하였다.

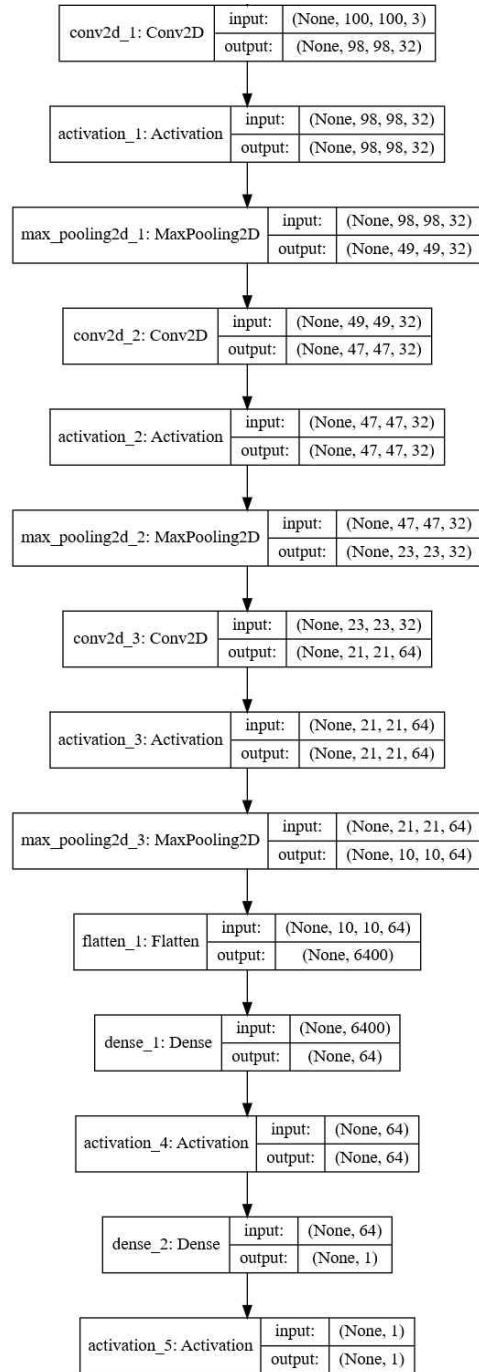


그림 19. Basic 모델의 구성

## 6.2 Basic 모델을 통한 EMG 신호 데이터 분류 결과

설정된 모델을 기반으로 VGG와 비교하여 Raw EMG, Normalization 그리고 Spectrogram을 통해 이를 비교한다.

### 6.2.1 Raw EMG data를 통한 VGGNet과 Basic모델 비교

먼저 Raw EMG 데이터에 대한 accuracy를 비교하면 그림 19와 같다. 그림 19에서 Basic 모델이 D1, D2, D4에서 같거나 비슷하다. 하지만, D3의 경우 VGGNet이 약 50%의 결과를 보이지만, Basic 모델의 경우 약 85%로 상승하는 것을 알 수 있다. 즉, Basic 모델이 최소 85%이상의 정확성을 보인다.




그림 20. Raw EMG data를 통한 각 모델 간 정확도 비교

### 6.2.2 Normalization EMG data를 통한 VGGNet과 Basic모델 비교

Normalization에 대한 Accuracy 결과는 그림 20과 같다. VGGNet에서 Accuracy가 약 50%인 데이터에 대해서 Basic 모델은 약 89%의 성능 향상을 보였다. 하지만, D1, D3, D4의 경우 비슷하거나 조금 떨어지는 정확성을 가진다. 즉, 아직까지도 Basic 모델이 정확성을 향상시킬 수 있는 방안을 만들어내지 못하고 있다. 이는 입력 데이터의 영역이 서로의 영역을 침범하는 결과를 보이기 때문이다. 또한, 센서별로 특정한 값을 제대로 반영하지 못 하는 것을 의미한다.




그림 21. Normalization EMG data를 통한 각 모델 간 정확도 비교

### 6.2.3 Spectrogram EMG data를 통한 VGGNet과 Basic모델 비교

Spectrogram EMG data를 통한 정확도를 Basic 모델을 통해 알아보면 그림 21과 같다. 그림 21에서와 같이 모든 데이터 형태(D1, D2, D3, D4)에 대해서 VGGNet보다 향상된 결과를 보인다. 특히, D4의 경우 VGGNet에서 약 66%의 정확도에서 81%의 정확도 향상을 가짐을 볼 수 있다. 즉, 어떠한 경우에서도 향상된 정확도를 보인다.




그림 22. Spectrogram EMG data를 통한 각 모델 간 정확도 비교

## 6.3 데이터의 특성을 파악한 새로운 이미지화 방안

위의 결과를 따라 VGGNet보다는 대체적으로 Basic 모델이 정확도를 높일 수 있는 모델이라 할 수 있다. 하지만 여전히 정확도에서는 Raw EMG, Normalization, Spectrogram에서 최소 53%의 낮은 정확도를 보이고 각 데이터 특성에 따라서도 낮은 정확도 결과를 갖는다. 따라서 이를 보완하기 위해서 새로운 방식의 데이터 형태를 제시해야 한다.

### 6.3.1 Stack을 이용한 센서별 가중치 설정에 따른 이미지화

EMG 신호 데이터는 센서별로 힘에 따른 다른 데이터를 전송한다. 하지만 모든 센서가 같은 힘의 변화에 따라 데이터 값이 증가하거나 감소하지는 않는다. 즉, 힘과 관련된 센서들만 데이터 값이 상승한다. 나머지 데이터는 일정한 값을 유지하거나 미세한 차이를 보일 뿐이다. 또한, 각 센서들은 힘의 변화는 결국 근육의 위치에 대한 값이기 때문에 힘을 발생시키는 근육의 주변으로 센서들의 값이 상승함을 알 수 있다. 전체적으로 보면 힘을 발생하는 센서에서의 비율이 힘을 발생하지 않는 근육에서의 센서보다 높은 비율을 차지하는 특성을 지닌다. 따라서, 각 센서에서 수집된 데이터를 Normalization을 통해 일정한 값을 추출하고 이를 각 센서별로 EMG 데이터의 전체 비중에서 이를 비율로 변환하여 이미지화 한다. 이러한 방법은 힘을 주는 경우와 그렇지 않은 경우, 힘을 많이 주는 경우와 조금 주는 경우와 같이 특정 센서에서의 EMG 데이터 변화를 쉽게 파악할 수 있다. 이러한 이미지는 다음 그림 22에서와 같다.






그림 22. (a) Stack을 통한 3D-Touch EMG 데이터 변환, (b) Stack을 통한 2D-Touch EMG 데이터 변환

그림 22-(a)는 힘을 주었을 때의 데이터를 이미지화 한 것이고, 그림 22-(b)는 힘을 조금 주었을 때의 데이터를 이미지화 한 것이다. 즉, 그림 22-(a)는 힘이 발생하는 근육의 센서들이 EMG 신호 값이 증가하기 때문에 각 센서에서 수집되는 EMG 신호 데이터의 비율이 일정하지 않다. 반면에 그림 22-(b)는 힘을 조금만 주기 때문에 센서간의 힘의 차이는 크게 발생하지 않는다. 따라서 각 센서간의 힘의 비율이 (a)보다는 균등하게 분포된다. 이를 통해 쉽게 둘의 차이를 구분할 수 있다.

### 6.3.2 제안한 이미지 프로세싱 기반 분류율

위에서 제안한 Basic 모델을 기반으로 각 데이터셋을 통해 정확도를 나타내면 그림 23과 같다. 그림 23에서와 같이 어떠한 데이터 셋과 상관없이 약 91%의 정확도를 보인다. 또한, 특히, D1, D2, D4의 경우 99%가 넘는 정확도를 보인다. D3의 경우 약 91%의 결과를 보이지만, 이전의 방법으로 분류했을 경우보다 최대 40%이상의 정확도가 높아진 것을 알 수 있다. 따라서, 작은 힘의 변화를 분류하기 위한 방안은 제안된 방안을 통해 분류가 가능하고 이를 통해 다양한 형태의 입력 방안에 사용될 수 있는 계기를 마련하였다.

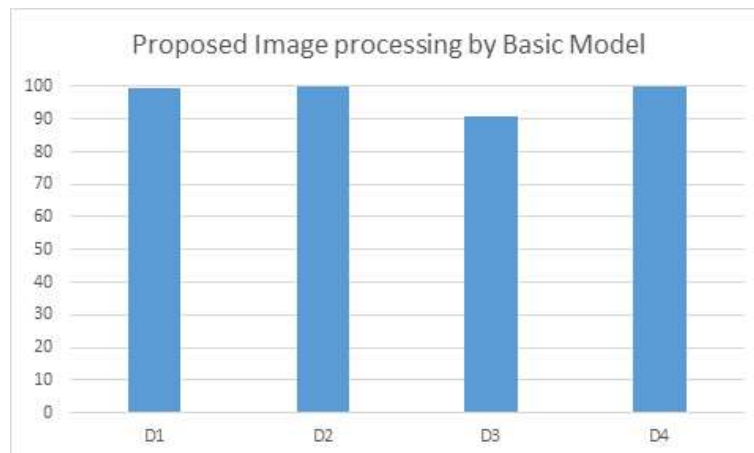


그림 23. Basic 모델을 통한 제안한 Stack EMG data  
분류 정확도 비교

## 제7장 결론

본 논문에서는 힘의 차이가 작은 근전도 신호를 CNN을 통해 분류를 하는 방안을 제시하였다. 이를 위해 힘의 차이가 작은 근전도 신호 데이터를 2D-Touch와 3D-Touch의 입력을 통하여 수집하였다. 2D-Touch와 3D-Touch 두 터치 입력 방식을 통해 수집한 데이터를 CNN 모델의 입력 데이터로 사용하기 위해 이미지화하는 과정을 진행하였다. 수집한 근전도 신호의 값을 어떠한 수정 없이 그대로 사용하는 Raw\_EMG data, 2D-Touch와 3D-Touch 두 터치 입력 방식을 통해 수집한 데이터를 CNN 모델의 입력 데이터로 사용하기 위해 이미지화하는 과정을 진행하였다. Raw, Normalization, Spectrogram으로 3가지의 이미지로 변환한 후, CNN의 대표적인 모델 중 하나인 VGG Net을 이용하여 분류한 결과 90% 이상의 성공률을 보였지만, 특정 피험자 또는 특정 데이터들이 잘 분류되지 않는 결과를 보였다. 따라서 VGG Net을 대체하기 위한 모델인 Basic 모델을 제작하였고, 앞서 사용한 3가지의 이미지화 방법 이외에 Stack이라는 이미지화 방법을 이용하여 추가적으로 데이터를 제작하였다. 이를 이용하여 분류한 결과 특정 피험자, 데이터를 잘 분류하지 못하는 기존의 VGG Net에 비해 잘 분류하는 결과를 보였다.

본 논문의 연구 결과를 통해 CNN 모델에서 미세한 힘의 차이를 가지는 근전도 신호를 잘 구분할 수 있도록 이미지화하는 방법을 제안하였다. 이를 통해 본 논문에서 미세한 힘의 차이를 가지는 행동으로 수행한 터치 입력 이외에 다양한 행동을 통하여 여러 미세한 행동을 구분할 수 있을 것으로 기대한다. 또한, 기존의 로봇 팔 또는 로봇 손을 제어하는 것보다 더 세밀하게 제어할 수 있는 보다 넓은 분야로 사용할 수 있고, 3D-Touch를 지원하지 않는 기기에서 근전도 신호를 이용하여 아이폰

의 ‘Peek’ 과 ‘Pop’ 에 대응하는 3D-Touch 인터페이스를 지원할 수 있을 것으로  
기대된다.

## 참 고 문 헌

- [1] A. F. T. Ibrahim, V. R. Gannapathy, L. W. Chong and I. S. M. Isa, “Analysis of Electromyography (EMG) signal for Human Arm Muscle: A Review” , Advanced Computer and Communication Engineering Technology, pp. 567-575, Dec 2015
- [2] S. Kumar, “Electromyography in ergonomics” , 2017
- [3] P. K. Artemiadis and K. J. Kyriakopoulos, “EMG-Based Control of a Robot Arm Using Low-Dimensional Embeddings” , International Journal of IEEE Transactions on Robotics, vol. 26, no. 2, pp. 393-398, April 2010
- [4] D. Leonardis, M. Barsotti, C. Loconsole et al, “An EMG-Controlled Robotic Hand Exoskeleton for Bilateral Rehabilitation” , International Journal of IEEE Transactions on Haptics, vol. 8, no. 2, pp. 140-151, April 2015
- [5] C. S. Nam and D. R. Shin, “Force-touch measurement methodology based on user experience” , International journal of Distributed Sensor Networks, vol. 14, no. 4, April 2018
- [6] K. Englehart et al, “Classification of the myoelectric signal using time-frequency based representations” , Medical engineering & physics, vol 21, no. 6, pp. 431-438, July 1999
- [7] K. Simonyan and A. Zisserman, “Very Deep Convolution Networks for Large-Scale Image Recognition” , International Conference on Learning Representations, May 2015
- [8] A. Waris, I. K. Niazi, M. Jamil et al, “Multiday Evaluation of Techniques for EMG-Based Classification of Hand Motions” , International Journal of IEEE

Biomedical and Health Informatics, vol. 23, no. 4, pp. 1526-1534, Aug 2018

[9] M. Liu, J. Shi, Z. Li et al, “Towards Better Analysis of Deep Convolutional Neural Networks” , International Journal of IEEE Transactions on Visualization and Computer Graphics, vol. 23, no. 1, pp. 91-100, Aug 2016

[10] “emg-data-sample” , <https://github.com/lmcgartland/swole/blob/master/Myo%20Data%20CSV%20Output/emg-data-sample.cpp>

[11] 박진혁, 남춘성, 이장열 외, “센서 부착위치와 독립된 EMG 데이터 자동분류 방안” , 한국소프트웨어종합학술대회, pp 260-262, 2018

[12] K. Englehart and B. Hudgins, “A robust, real-time control scheme for multifunction myoelectric control” , International Journal of IEEE Transaction on Biomedical Engineering, vol. 50, no. 7, pp. 848-854, June 2003

[13] A. Phinyomark, S. Hirunviriya, C. Limsakul, and P. Phukpattaranont, “Evaluation of emg feature extraction for hand movement recognition based on euclidean distance and standard deviation” , International Conference of IEEE Computer Telecommunications and Information Technology, pp. 856-860, 2010

[14] C. J. DeLuca , L. D. Gilmore, M. Kuznetsov and S. H. Roy, “Filtering the surface emg signal: Movement artifact and baseline noise contamination” , “International Journal of Biomechanics” , vol. 43, no. 8, pp. 1573-1579, May 2010

[15] K. Englehart, B. Hudgins, and P. Parker, “A wavelet-based continuous classification scheme for multifunction myoelectric control” International Journal of IEEE Transaction on Biomedical Engineering, vol. 48, no. 3, pp. 302-311, March 2001.

[16] M. Oskoei and H. Hu, “Myoelectric control systems a survey” International Journal of Biomedical Signal Processing and control, vol. 2, pp. 275-294, Oct 2007

[17] C. L. Fall, P. Turgeon, A. Campeau-Lecours et al, “Intuitive wireless control of a robotic arm for people living with an upper body disability” International

Conference of IEEE Engineering in Medicine and Biology Society (EMBC), pp. 4399-4402, 2015

[18] G. Tsenov, A. H. Zeghibib, F. Palis et al, “Neural networks for online classification of Hand and Finger movements Using Surface EMG signals” International Conference of Neural Network Applications in Electrical Engineering, pp. 167-171, Sept 2006

[19] U. C. Allard, F. Nougrou, C. L. Fall et al, “A convolutional neural network for robotic arm guidance using sEMG based frequency-features” International Conference of Intelligent Robots and Systems (IROS), pp. 2464-2470, Oct 2016

[20] Y. Du, W. Jin, W. Wei et al, “Surface EMG-based Inter-Session Gesture Recognition Enhanced by Deep Domain Adaptation” International Journal of Sensors, vol. 17, no. 3, Mar 2017

[21] B. Hudgins, P. Parker, and R. N. Scott, “A new strategy for multifunction myoelectric control” , International Journal of IEEE Transactions on Biomedical Engineering, vol. 40, no. 1 pp. 82-94, Jan 1993

## ABSTRACT

# A Study on EMG Signal Classification with Small Force Difference Using CNN

Park Jin Hyuck

Department of Electrical and Computer

Engineering

Sungkyunkwan University

EMG signals are electrical signals generated by muscle cells that are activated when a person takes a specific action. The research that tried to use it in various fields was conducted. The general application field of the EMG signal is used for medical examination or recycling of human in the medical field, and the industrial field is used for controlling the robot arm or the robot leg using the EMG signal of the worker. However, research to date has focused on the classification of behaviors with large force differences and the control of devices such as robot arms and robot legs. There are few ways to classify behaviors with subtle force differences. Therefore, in this paper, we propose a method to classify EMG signals with small force differences. Data is collected through 2D-Touch and 3D-Touch input methods for measuring EMG signals with subtle force differences. The collected data is classified through CNN (Convolutional Neural Network).



Data collected via two touch input methods, 2D-Touch and 3D-Touch, were then imaged to use as input data for CNN models. After converting to three images with Raw, Normalization, and Spectrogram, the classification using one of the leading models of CNN, using VGG Net showed a success rate of over 90%, but certain subjects or specific data were not well classified. Thus, the Basic model was created to replace VGG Net, and in addition to the three imaging methods used earlier, additional data was created using the imaging method called Stack. The results of this classification show that specific subjects are better classified than traditional VGG Net, which is not well classified. Based on the results of the study in this paper, it is expected that the field of field with minor force differences can be used as a larger area, and that the 3D-Touch interface can be supported by using the superconducting signal in devices that do not support 3D-Touch.

**Keywords:** 2D-Touch, 3D-Touch, EMG, VGG Net

(표지측면)

碩  
士  
學  
位  
請  
求  
論  
文

CNN  
을  
이용  
한  
작은  
힘의  
차이  
를  
가지  
는  
근전  
도  
신호  
분류  
에  
관한  
연구

2  
0  
2  
0

朴  
- 41 -  
辰  
赫

